REV-P · Transferência de conhecimento físico por IA geoespacial auditável para análise de suscetibilidade a inundações em comunidades brasileiras com poucos registros

Gabriela Sofia, Bárbara Borges, Nicole Guarnieri e Rafaella Guerra
Bacharelado em Ciência da Computação – Pontifícia Universidade Católica do Paraná (PUCPR)
{gabriela.milani, barbara.borges, nicole.guarnieri, rafaella.guerra}@pucpr.edu.br

***Resumo*—O REV-P (Reconhecimento de Evidências Verificáveis para Predição) é uma ferramenta e um método de inteligência artificial geoespacial para analisar a suscetibilidade a cheias em comunidades com poucas observações locais. O método aprende relações entre terreno, drenagem e água em cheias documentadas e avalia sua transferência para territórios brasileiros. A ferramenta apresenta uma ordem de suscetibilidade, explica a contribuição das variáveis e identifica as fontes. Quando há imagens de radar adequadas, um módulo de visão computacional detecta água e acrescenta essa evidência à resposta.**

***Palavras-chave*—Suscetibilidade a cheias; transferência; IA geoespacial; evidências verificáveis; territórios vulnerabilizados.**

I. Introdução

Uma enchente é, ao mesmo tempo, um fenômeno físico e um acontecimento na vida de alguém: a água segue o relevo, mas o que ela leva embora depende de quem mora no caminho [1]. No Brasil, o Instituto Brasileiro de Geografia e Estatística (IBGE) inclui a localização em áreas de risco ambiental entre os critérios que identificam as 12.348 Favelas e Comunidades Urbanas (FCU), onde vivem cerca de 16,4 milhões de pessoas [2]. A observação do fenômeno nesses territórios é escassa: no acervo inicial do projeto, apenas uma comunidade tinha água observada, e nenhuma reunia locais com e sem água em número suficiente para ajuste e avaliação locais. A falta de registros reduz tanto a visibilidade das ocorrências quanto a evidência disponível para analisá-las.

Tal escassez de referências une o problema social ao desafio científico: os registros que dão visibilidade às ocorrências vividas pelas comunidades também sustentam o aprendizado e a avaliação dos modelos. Uma inteligência artificial (IA) aprende com os exemplos disponíveis, e quem nunca entrou no registro também não entra na resposta. A literatura sobre mapeamento de suscetibilidade urbana a inundações já reúne cerca de 160 abordagens [3]. Essa diversidade metodológica, contudo, não eliminou a dificuldade de levar o aprendizado a lugares distintos dos de treino, e modelos guiados só por dados podem se apoiar em correlações espúrias e super-representar as regiões mais ricas em dados [4], [5]. Esperar que cada comunidade acumule os próprios registros seria aceitar que ela só possa ser analisada depois de inundar muitas vezes.

Este trabalho parte de outra possibilidade: como a água responde ao terreno segundo as mesmas leis em qualquer lugar, aquilo que se aprende onde o fenômeno foi bem observado pode carregar conhecimento para onde ele nunca foi. A hidrologia levou a bacias sem monitoramento um modelo treinado em 531 bacias, e a ideia alcançou a suscetibilidade urbana e o mapeamento orbital de cheias [6]–[9]. Restava verificar se esse conhecimento chega às comunidades brasileiras.

A pergunta que guia o trabalho é: **como uma IA geoespacial auditável pode aprender mecanismos transferíveis de suscetibilidade urbana a enchentes, a partir de evidências físicas, observacionais, sociais e científicas, e levá-los a territórios brasileiros com pouca referência local, preservando limites de validação?**

O Reconhecimento de Evidências Verificáveis para Predição (REV-P) responde com um método e uma ferramenta. O método qualifica observações de cheia, aprende em 59 eventos no exterior como combinar atributos do terreno e aplica os pesos, sem ajuste local, para ordenar pontos em territórios brasileiros. A ordem é confrontada com evidências reservadas e pode ser atualizada com exemplos locais, enquanto unidades fora do treino medem se o aprendizado da origem se preserva.

A ferramenta apresenta, por coordenada, a posição relativa do local, a contribuição de cada variável, a versão do modelo, as fontes e o suporte da resposta, inclusive quando a evidência é insuficiente. Camadas sociais do Censo contextualizam quem vive nos lugares analisados, uma busca documental recupera a literatura, e uma etapa de verificação examina se as fontes sustentam as afirmações. A contribuição reside em articular um método que separa o que se aprende do que se verifica a uma ferramenta que torna auditável cada resposta.

A visão computacional atua em três frentes. A comparação de cenas ópticas de antes e durante a cheia e as delimitações orbitais qualificadas indicam onde houve água, fornecendo os rótulos do ajuste e as referências de conferência. Uma rede U-Net delimita a água em imagens de radar, que observam a superfície sob nuvens, e essa delimitação acompanha a resposta como evidência observacional. O treino mascarado oculta blocos do radar e do terreno e treina a rede para reconstruí-los, o que aproveita imagens sem rótulo onde as anotações são raras. O escore é calculado com o terreno e permanece disponível onde não há imagem da cheia: a imagem observa e confere, e o terreno viabiliza a transferência.

Os destinos respondem a perguntas complementares. A Região Metropolitana de Porto Alegre (RMPA), em maio de 2024, reúne 6.117 dos 10.545 positivos e permite avaliar a transferência e o que poucos exemplos locais acrescentam. Manaus (Rio Negro, 2021) e a Região Metropolitana de Curitiba (RMC, Iguaçu, 2023) estendem o teste a outras bacias e episódios. Recife e sua região metropolitana (RMR) separam a capital do entorno em 2022, e, nela, os atendimentos da Defesa Civil permitem testar a ordenação por rua. Petrópolis examina outro fenômeno: as cicatrizes de deslizamento de 2022 registram rupturas de encosta, processo distinto do acúmulo de água, e conferem um modelo próprio. Em todos, o resultado é uma priorização relativa, e não uma previsão de quando ou com que profundidade a água chegará.

II. Método da ferramenta

A Fig. 1 sintetiza o percurso dos dados, da observação da cheia à resposta por território.

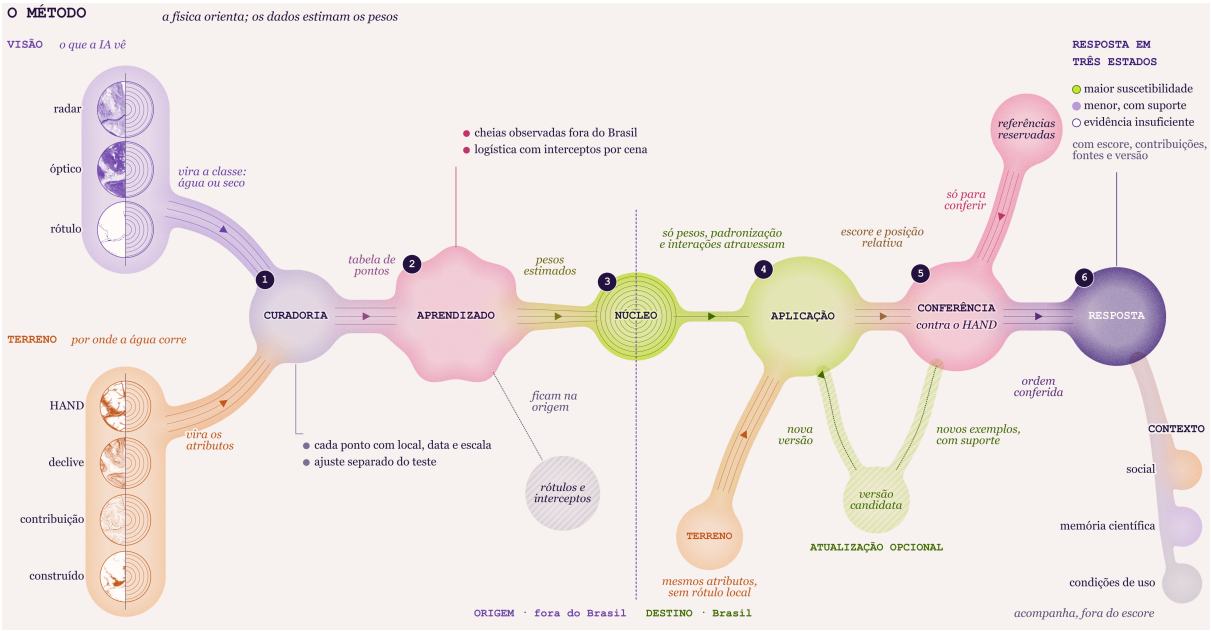


Figura 1. Fluxo do REV-P. Lilás indica as observações que geram rótulos e laranja, os atributos do terreno. Rosa marca o ajuste e a conferência com referências reservadas. Verde acompanha a transferência dos pesos e a atualização opcional. Roxo indica a resposta com escore, suporte, fontes e contexto.

A. Curadoria das observações

O inventário reúne 1.641.356 observações e registra, para cada uma, local, data, fonte, escala, classe e usos autorizados. Cada observação é classificada como presença, comparador, água permanente ou evidência insuficiente, segundo o fenômeno e o instrumento. A curadoria identificou 763.155 registros aptos ao treino e 513.530 à avaliação externa, e a separação entre ajuste e teste é definida em cada ensaio.

Para o ajuste externo, agrupamos 36.331 pontos em 43 unidades de evento e sub-bacia: 16.633 de delineações do Copernicus Emergency Management Service (CEMS), 11.698 de rótulos manuais do UFO (3 m) e 8.000 do Sen1Floods11 (10 m) [10]–[12]. O teste externo usa manchas MODIS do Global Flood Database (GFD, 250 m) [13]. Mancha é o contorno da área atingida, traçado em imagem de satélite; o GFD e o ciclone Idai a usam por cobrir regiões sem medição.

Muçum (RS) ilustra a referência óptica: cenas Sentinel-2 de 21 de abril e 6 de maio de 2024 (Fig. 2e–f). O índice de água por diferença normalizada modificado (MNDWI, h) compara o verde com o infravermelho de ondas curtas, faixa em que a água absorve a radiação. Marca-se água se o índice for positivo em leitura válida de 20 m [14].

A classificação de cena (SCL), painel (m), exclui nuvem, sombra e falta de dado. Água nova exige índice positivo na cheia e leitura anterior válida sem água; um ponto válido sem água durante a cheia serve de comparador. Água anterior ou permanente, com apoio da camada do Joint Research Centre quando disponível, e leituras insuficientes ficam em classes à parte [15].

As manchas do CEMS de maio de 2024 (EMSR720) integraram só o núcleo congelado, avaliado fora do Brasil.

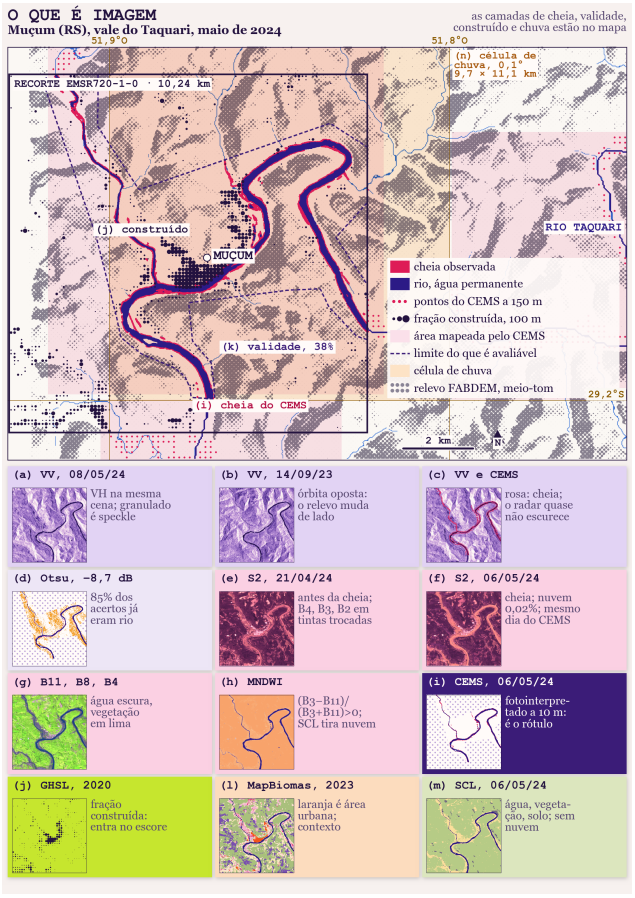


Figura 2. Muçum (RS). Cenas antes e durante a cheia (e–f), índice de água (h), validade da leitura (m) e referência independente do CEMS (i), delimitada por analistas em imagem Pléiades Neo do mesmo dia. Recorte ilustrativo.

A RMPA testa a versão treinada no exterior, com a cena Sentinel-2 de 6 de maio, validada com uma mancha Planet/SkySat do Guaíba [16].

Em Recife, localizamos por endereço os relatos à Defesa Civil e reunimos os registros pela unidade rua–bairro. As ruas com relato são comparadas às demais do próprio bairro, o que reduz diferenças de notificação. Como a extensão da rua pode influenciar o registro, repetimos a análise com pares de comprimento semelhante [17], [18].

Em Petrópolis, o Instituto Nacional de Pesquisas Espaciais (INPE) mapeou, pelo Charter, as cicatrizes de fevereiro de 2022, e as células fora delas formam o fundo. O inventário histórico da UFRJ/GEOCART localiza danos por endereço e amplia o registro nas comunidades [19], [20].

B. Atributos do terreno

O IBGE fornece os contornos georreferenciados das FCU, que sobrepomos a um modelo digital de terreno por unidade para extrair atributos em células de cerca de 30 m, no interior e no entorno das comunidades. Assim, a ferramenta consulta o terreno por coordenada, e a análise separa os pontos das FCU dos do recorte urbano [21].

Na Fig. 3, a elevação (c) informa a altitude e o declive (d) mede a inclinação local. Para calcular o *Height Above Nearest Drainage* (HAND, e), seguimos o caminho de escoamento D∞ até a drenagem conectada e subtraímos a cota desta da cota do ponto. A regra HAND prioriza os pontos de menor altura, que uma elevação menor do nível da água na drenagem é suficiente para alcançar [22].

A área de contribuição (f) é o terreno a montante que drena até o ponto. As distâncias à drenagem e aos canais com contribuição $\geq$10 km^2 medem a conexão à rede. Com HAND, declive, fração construída (GHSL) e areia (SoilGrids), elas formam os sete atributos do núcleo, e o declive mediano do recorte modula as interações. Em Recife, os atributos são agregados por rua dentro do bairro. A chuva situa o evento no tempo e fica fora do escore [23]–[25].

C. Aprendizado e transferência

A regressão logística regularizada aprende a distinguir pontos rotulados com água dos comparadores. Cada evento recebe o mesmo peso total, com as classes balanceadas em seu interior, e um intercepto ajusta o nível do escore em cada cheia [26]. Para o ponto i, cada atributo padronizado x_{ij} contribui com seu peso β_j. Nos pares selecionados $\mathcal{I}$, o peso γ_{jk} multiplica o produto dos atributos, o que permite, por exemplo, que a contribuição da distância à drenagem varie com o relevo do recorte:

$$s_i = \sum_j \beta_j x_{ij} + \sum_{(j,k)\in\mathcal{I}} \gamma_{jk} x_{ij} x_{ik}.$$

No destino, extraímos os mesmos atributos em cada coordenada (Fig. 3l) e aplicamos a padronização, os pesos e as interações da origem; os interceptos ficam nas cheias de ajuste.

O escore é a soma das contribuições e determina a posição relativa de cada ponto, de modo que a equação identifica os termos que separam pontos com HAND semelhante.

A versão externa completa atende à avaliação nas comunidades. A versão com reserva ajusta 29 unidades e mantém 14 fora do treino para responder ao que a completa não alcança: se os pesos dependem das unidades de ajuste e se uma atualização local preserva o que foi aprendido. Essas 14 unidades também calibram a resposta, e essa versão serve às ruas de Recife e à atualização local. Para o teste fora do país, ajustamos o núcleo congelado com 91.446 observações, incluindo eventos brasileiros.

Petrópolis requer outro modelo, pois o deslizamento decorre da ruptura da encosta, governada por inclinação e forma do terreno, enquanto a água se acumula nas partes baixas [27]. A relação também foi aprendida fora do Brasil, no inventário de 14.900 rupturas do ciclone Idai (Zimbábue, 2019), com outra regressão logística sobre sete atributos do FABDEM a 30 m e sem HAND [28].

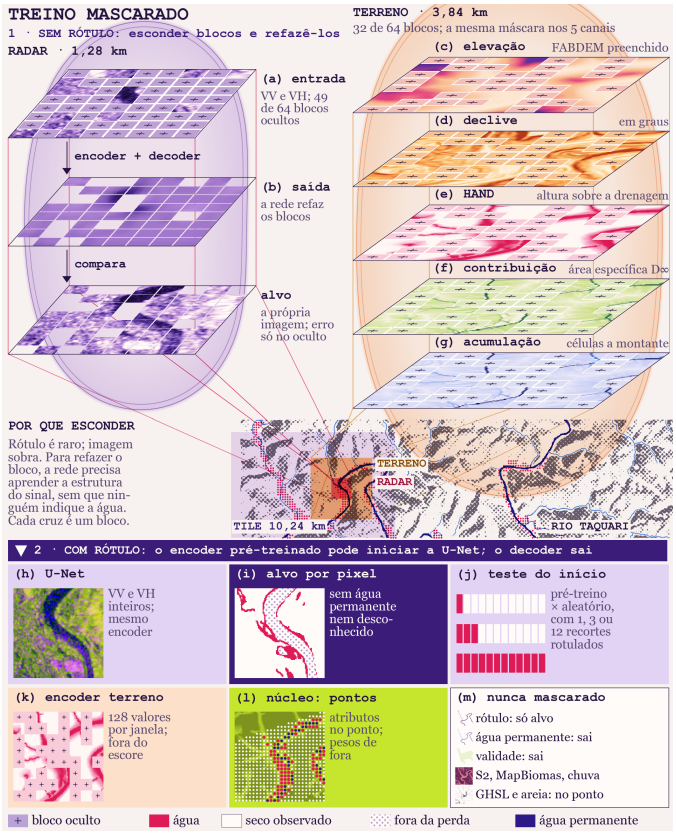


Figura 3. Treino mascarado em Muçum (RS). Sem rótulo, a rede refaz blocos ocultos do radar (a–b) e do terreno (c–g). O encoder pode iniciar a U-Net (h–i), e o teste compara esse início ao aleatório (j). O núcleo lê atributos por ponto (l). O pré-treino usa Sen1Floods11; a saída (b) é demonstrativa.

Para identificar a água do evento, uma U-Net recebe as polarizações VV e VH do radar de abertura sintética (SAR) do Sentinel-1 e segmenta a água pixel a pixel, inclusive sob nuvens (Fig. 3h–i). Usamos 446 recortes anotados, com 90 para teste.

A interseção sobre união (IoU) divide a área comum à máscara estimada e à referência pela área coberta por ao menos uma delas [29].

Como recortes anotados são escassos, o pré-treino mascarado aproveita imagens sem rótulo (Fig. 3a–b). A rede recebe o radar com 75% dos blocos de 16×16 pixels ocultos e reconstrói VV e VH. O erro é calculado apenas nos blocos ocultos com leitura válida, o que obriga o encoder a representar o contexto em vez de copiar a entrada [30]. O decoder é então descartado, e o encoder, idêntico ao da U-Net, pode iniciar o ajuste supervisionado.

Para medir a utilidade desse início, comparamos em oito eventos do Sen1Floods11 a rede pré-treinada à iniciada aleatoriamente, com 1, 3 ou 12 recortes rotulados por contexto (Fig. 3j). A métrica é a precisão média (AP), e uma vantagem exige intervalo acima da margem de 0,025. No terreno, o mesmo procedimento oculta metade dos blocos de cinco camadas (c–g) e produz 128 valores por janela de 3,84 km (k), mantidos fora do escore. No ajuste em sequência, o método Learning without Forgetting (LwF) usa as saídas da rede anterior para preservar o aprendizado [31].

D. Avaliação e atualização

Em cada destino, o REV-P e a regra HAND ordenam os mesmos pontos, e as duas ordens são cruzadas com a referência reservada: nas coortes brasileiras, a comparação das cenas Sentinel-2 identifica água nova e comparadores (Fig. 2e–f); no teste externo, as manchas do GFD cumprem esse papel.

A área sob a curva ROC (AUC) resume a conferência por pares. Em cada par, formado por um ponto com água e um comparador, conta-se um acerto se o ponto com água vier primeiro e meio acerto em caso de empate. AUC de 0,80 equivale a oito acertos a cada dez pares; uma ordem ao acaso tem AUC esperada de 0,50, e uma ordem perfeita, de 1,00. Cada AUC mede a tarefa própria de sua unidade: células, ruas ou cicatrizes [32].

O ganho da combinação de atributos é a AUC do REV-P menos a AUC da regra. Sua incerteza vem de 2.000 reamostragens pareadas de grupos inteiros, como comunidades nas FCU e componentes de cheias no teste externo, para não tratar pontos vizinhos como independentes.

Um intervalo todo acima de zero sustenta a vantagem do REV-P. Cada estrato avaliado reúne ao menos 20 pontos com água, distribuídos em pelo menos 10 grupos. No teste externo do núcleo congelado, hipótese, população e regra de decisão foram definidas antes da análise, com nível de confiança ajustado para três hipóteses.

A associação entre HAND e água é estimada dentro de cada cheia e entre pontos próximos, o que reduz a influência das diferenças entre eventos e regiões. A retirada de famílias de atributos mede o que cada uma acrescenta à ordenação, e a avaliação em unidades deixadas de fora, uma de cada vez, indica se o ganho sobre o HAND se repete em cheias ausentes do ajuste [33].

A atualização incorpora exemplos do destino sem refazer o aprendizado externo. A referência é consultada em B pontos, escolhidos perto do limiar de decisão, onde o modelo mais hesita, ou por sorteio, e uma correção regularizada soma-se ao escore transferido: $s_i^{(B)} = s_i^{(0)} + r_B(\boldsymbol{x}_i)$.

A correção entra em uso com ao menos cinco positivos, cinco negativos e três grupos positivos; sem esse suporte, a ferramenta conserva a versão externa. O ganho é medido no destino e a retenção, nas unidades reservadas [34].

E. Resposta e auditoria

O mapa classifica cada local em maior suscetibilidade, menor suscetibilidade com suporte ou evidência insuficiente, e uma resposta baixa só aparece onde há base para ela. A triagem é avaliada pelos pontos com água que deixam de receber resposta baixa quando a seleção por margem substitui a aleatória, com a mesma meta de cobertura. Os dados do Censo acrescentam quem vive em cada comunidade, se houve água observada e se há ao menos cinco pontos de cada classe.

A resposta vem acompanhada do que a sustenta. A busca documental separa a literatura científica dos registros de procedência, e sua capacidade de achar a fonte certa é medida em consultas sintéticas de fonte conhecida. O exame de cada frase combina regras e um juiz que avalia se a fonte a sustenta. A auditoria numérica recompõe o escore a partir dos atributos e da versão, o que a torna reproduzível.

III. Resultados

A. Relações físicas e ganho no teste externo

A Tabela I examina a relação física, mede o ganho sobre o HAND fora do ajuste e, com a reserva, mostra se os pesos dependem das cheias de treino.

Tabela I
Relações aprendidas. O sinal do HAND se repete entre territórios, e a conexão à drenagem acrescenta informação no teste externo.

Comparação ou condição	Estimativa	IC ou referência
HAND e água observada		
Muçum: mediana do HAND	2,2 m com água	61,2 m no comparador
Dentro da cheia, 331.492 pontos[a]	−1,13	[−1,31; −0,96]
Pares a até 3 km[a]	−1,27	[−1,48; −1,05]
HAND maior, menos água em 25 de 27 territórios.		
Diferença de AUC ao testar 43 unidades, uma por vez		
Modelo geral − HAND	+0,039	[0,026; 0,054], 33 a favor
Retirar pistas de acumulação	−0,064	[−0,080; −0,048], 39 pioram
Teste externo: diferença de AUC		
Núcleo − HAND[b]	**+0,055**	[0,024; 0,086]
Com − sem atributos de conexão[b]	**+0,030**	[0,006; 0,053]
Regressão − HAND, 16 cheias[c]	**+0,041**	13/16, p=0,011

Peso por atributo	Completa	Reserva	Peso por atributo	Completa	Reserva
HAND (log)	−0,981	−0,904	Areia	−0,051	−0,202
Distância ao canal	−0,429	−0,433	Contribuição (log)	+0,043	+0,085
Declive	−0,312	−0,274	Dist. à drenagem	+0,030	+0,055
Fração construída	−0,210	−0,170			

Pesos: versões completa e com reserva (14 unidades fora do ajuste). Os sete atributos conservam o sinal. IC95%, exceto [b]. [a]Log da razão de chances por desvio-padrão de HAND. [b]Núcleo ajustado com dados brasileiros e testado em 30 grupos do GFD fora do país. IC98,33%. [c]Cheias sul-americanas fora do Brasil.

B. Transferência para comunidades brasileiras

Os pesos aprendidos no exterior foram aplicados às comunidades e ao recorte urbano de cada destino (Tabela II). O primeiro bloco mede a tarefa que motiva o método, o segundo verifica se a vantagem se mantém na área inteira, e o último reúne duas verificações da conferência.

Tabela II
TRANSFERÊNCIA SEM AJUSTE LOCAL. NAS COMUNIDADES DE MANAUS, RECIFE E RMR, O REV-P SUPEROU O HAND.

Nas FCU	Pos. (FCU)	AUC do REV-P	Δ HAND [IC]	Δ declive
RMPA	241 (17)	0,880 [0,828; 0,923]	—	—
Manaus	48 (10)	0,920 [0,791; 0,967]	**+0,046** [0,020; 0,069]	**+0,111**
Recife	31 (19)	0,866 [0,777; 0,935]	**+0,064** [0,012; 0,125]	**+0,151**
RMR	366 (35)	0,809 [0,721; 0,866]	**+0,116** [0,069; 0,145]	**+0,093**

Área	Pos.	AUC	Δ HAND [IC]	Δ declive	Baixa renda	Ref. urb.
RMPA	6.117	0,905	**+0,016** [0,005; 0,025]	—	0,884	0,907
Manaus	215	0,791	**+0,036** [0,0004; 0,061]	**+0,105**	—	0,804
RMC	883	0,811	—	**+0,056**	—	0,812
Recife	448	0,781	**+0,043** [0,019; 0,068]	**+0,087**	0,844	0,739
RMR	2.882	0,775	**+0,085** [0,055; 0,106]	**+0,069**	0,770	0,748

Rótulos embaralhados	Queda de AUC de 0,30 a 0,63
Outro sensor	99% dos positivos da RMPA na mancha Planet/SkySat

Pos.: pontos com água nova. Entre parênteses, FCU com água. Área: recorte inteiro, com pontos fora das FCU (10.545 positivos). Baixa renda e ref. urb.: AUC por estrato. Δ: AUC do REV-P menos a da regra indicada. Colchetes: IC95%. —: sem vantagem sustentada ou abaixo do mínimo de positivos. RMC, FCU: 11 positivos. Sentinel-2: RMPA 05/2024, Manaus 06/2021, RMC 11/2023, Recife e RMR 05/2022. RMR exclui Recife.

C. Ordenação de ruas com relatos em Recife

Os relatos avaliam o escore por rua, e a decomposição de duas vias do mesmo bairro mostra o que explica sua posição (Tabela III).

Tabela III
RECIFE. O REV-P PRIORIZOU RUAS COM RELATOS MELHOR QUE O HAND; A DECOMPOSIÇÃO ABRE A CONTA EM DUAS RUAS DE ESTÂNCIA.

Comparação dentro do bairro	Resultado	IC ou referência
2014–2024: 1.648 relatos, 420 localizados até a rua, 96 ruas em 38 bairros. Em 16 de 71 bairros com registro, a ocorrência apareceu apenas nos relatos.		
Teste: 48 ruas com relato em 19 bairros, entre 2.225 ruas		
AUC do REV-P	0,669	[0,564; 0,775]
AUC do HAND	0,595	[0,491; 0,711]
Ganho de AUC sobre o HAND	**+0,074**	[0,012; 0,159]
Ruas com relato no topo de 20%	42%	HAND: 31%
Ganho em pares de comprimento semelhante[a]	+0,058	[−0,024; 0,177]

Parcela do escore	Muriti	Av. Recife	Parcela do escore	Muriti	Av. Recife
HAND (log)	+0,751	+0,204	Areia	+0,033	+0,033
Dist. ao canal	+0,853	+0,093	Área que drena (log)	+0,129	−0,013
Declive	+0,272	+0,123	Dist. à drenagem	−0,026	+0,023
Fração construída	−0,525	−0,406	**Escore final**	**1,487**	**0,057**
Número de relatos				3	4
Ruas com escore menor (de 74)				72	12

REV-P com reserva. Colchetes: IC95%. [a] Razão dos comprimentos até 1,5. Escore de ordenação: contribuições $\beta_j x_{ij}$ e interações ($|\gamma| \leq 0{,}027$).

D. Modelo de encostas em Petrópolis

A relação aprendida no Idai foi conferida com as cicatrizes de 2022 e comparada ao modelo de água (Tabela IV).

Tabela IV
PETRÓPOLIS. O MODELO DE ENCOSTAS ORDENOU AS CICATRIZES MELHOR QUE O MODELO DE ÁGUA.

Modelo ou comparação	AUC ou ganho	IC95%
Modelo de água	0,375	[0,307; 0,445]
Modelo de encosta treinado no Idai	0,660	[0,593; 0,726]
Encosta − modelo de água	**+0,286**	[0,170; 0,396]
Externo com exemplos locais − só local[a]	**+0,126**	[0,070; 0,180]

Avaliação: 81 cicatrizes e 12.170 células de fundo. Idai: AUC 0,885 em 13 blocos retidos de 10 km. Topo de 20%: 40% das cicatrizes. Registro interno passou de 5 para 20 das 42 FCU. 31 FCU a até 100 m. [a] Ajustes com 100 consultas.

E. Atualização local na RM de Porto Alegre

A RMPA reúne exemplos suficientes para medir o ganho no destino, e a reserva revela o efeito na origem (Tabela V).

Tabela V
ATUALIZAÇÃO LOCAL. A MARGEM MELHOROU A ORDENAÇÃO NAS FCU DA RMPA, E A RESERVA MEDE O EFEITO NA ORIGEM.

Atualizado − sem atualizar	Ganho em AUC	IC95%	Rep.
FCU da RM de Porto Alegre, 400 consultas			
Margem (AUC de 0,874 a 0,926)	**+0,052**	[0,020; 0,101]	6/6
Pontos escolhidos por sorteio	**+0,029**	[0,009; 0,062]	6/6
Destino: amostra inteira da RM de Porto Alegre			
Atualização com 400 consultas	**+0,021**	[0,015; 0,026]	
Reserva da origem e memória			
Origem após ajuste por margem	−0,028	[−0,056; −0,006]	
FCU, memória de 200 exemplos[a]	+0,017	[0,006; 0,027]	

6/6: repetições do mesmo episódio. Retenção medida em seis unidades externas. Em Manaus e na RMC, o filtro conservou a versão externa por falta de positivos, evitando perda de 0,078 de AUC em Manaus. [a] Ciclo com memória em três destinos.

F. Cobertura observacional e módulos de apoio

A ampliação do acervo levou a observação de água a mais comunidades (Tabela VI).

Tabela VI
COBERTURA OBSERVACIONAL. O ACERVO AMPLIOU A OBSERVAÇÃO NAS COMUNIDADES.

Recorte total[a]	1.708 FCU, 2.776.821 moradores
FCU com água	De 1 no acervo inicial a 123 de 1.666 no recorte ampliado
Suporte nas 123 FCU	119 com as duas classes. Em 38, há ≥5 pontos por classe.

[a] Universo censitário, inclui 42 FCU de Petrópolis.

O início pré-treinado elevou a detecção de água justamente onde há menos rótulos: com um único recorte rotulado por contexto, a precisão média subiu em sete de oito eventos (Tabela VII).

Tabela VII
MÓDULOS DE APOIO, AVALIADOS À PARTE DO ESCORE.

Módulo	Métrica e comparação
Mapa de água, 90 recortes[b]	Sobreposição (IoU) da U-Net: 0,449
Pré-treino, 8 eventos[d]	Pré-treinado − aleatório: ΔAP +0,041 [0,014; 0,069], 7/8, com 1 recorte; +0,050 com 3
SAR contínuo, 8 unidades	LwF: ΔIoU **+0,049** [0,029; 0,068], limiar 0,2
Busca, 11.238 consultas	Nas 5 primeiras: 44,35% híbrida vs. 36,65% lexical
Juiz + regras vs. regras (18)	Acerto: 0,722 vs. 0,444. Falsos positivos: 1 vs. 7
Água com resposta baixa[c]	Margem vs. sorteio: RMPA 0 vs. 35, RMR 25 vs. 130
Reprodução do escore	147.798 pontos, erro máximo $3{,}56\times10^{-15}$
Conferência do serviço	2.747 testes (20/10), 922 fontes por hash, 5 portões

[b] Por pixel, sem água permanente; U-Net sem pré-treino. [c] Nas FCU; meta de 70% de cobertura na coorte. [d] Intervalo não supera por inteiro a margem de 0,025.

IV. DISCUSSÃO

A recorrência do sinal do HAND tem explicação física. O descritor mede a altura do ponto em relação à drenagem, e a área de contribuição indica onde o escoamento converge e a saturação começa [22], [23]. Como esses conceitos descrevem o movimento da água, e não um lugar, espera-se que mantenham a direção entre regiões. A estabilidade não demonstra causa, mas justifica tratar como mecanismo transferível uma relação preditiva de motivação física [33].

A transferência alcança os pesos, e não o nível do escore, pois amostrar por classe altera o intercepto da regressão logística e preserva as inclinações [26].

O resultado dialoga com a hidrologia de grandes amostras, em que um modelo sem dados da bacia alcançou eficiência mediana de 0,69, contra 0,64 do modelo calibrado em cada uma das 531 bacias [6]. O alvo ali é a vazão no tempo, e as métricas não se comparam, mas o princípio é o mesmo. A transferência em suscetibilidade urbana já contornou a escassez de inventários em bacias de Pequim, e o mapeamento orbital passou a examinar a generalização fora da área de treino [8], [9]. O REV-P leva essa pergunta para dentro das comunidades, e sete atributos de significado físico, legíveis na resposta, bastaram para superar o HAND numa literatura com modelos de 5 a mais de 20 parâmetros [3].

O significado social está na observação. A exposição das favelas já foi medida em escala global [35]. Aqui se acrescenta a conferência dentro delas, onde a vantagem sobre o HAND foi maior do que na área inteira em Manaus, Recife e na RMR. Como a ausência de chamado não equivale à ausência de água, comparar ruas dentro do bairro aplica o princípio de que o fundo deve partilhar o viés de registro das presenças [18].

A fronteira do que se transfere é dada pelo processo. Cheias de origens físicas distintas pedem leituras distintas [27]. Em Petrópolis, o modelo de água ficou abaixo do acaso nas cicatrizes, e o aprendido nas rupturas do Idai as ordenou, pois a água procura as partes baixas, e a ruptura nasce na encosta [28].

Conhecimento externo e observação local se somam. O ganho maior das consultas por margem é o esperado quando a informação nova se concentra na fronteira de decisão, e medir separadamente ganho e retenção faz da reserva um critério de uso [34]. Na percepção, o início pré-treinado é útil justamente com poucos rótulos, finalidade do treino mascarado [30].

Como AUC por grupos não equivale à acurácia de um mapa, a ferramenta apresenta a ordenação como priorização relativa [32]. Os ensaios nas coortes brasileiras são de desenvolvimento, e confirmar a transferência em comunidades inéditas pede episódios independentes.

V. Conclusão

Em resposta à pergunta de pesquisa, uma IA geoespacial auditável pode aprender relações físicas em cheias documentadas e transferi-las, sem ajuste local, aos territórios brasileiros avaliados: a direção da relação se repete, a combinação de atributos superou a regra HAND no teste externo e em Manaus, Recife e na RMR, e cada resposta expõe sua conta, suas fontes e o que falta observar. Quando o processo muda, como nas encostas de Petrópolis, o método aprende outro modelo com a mesma lógica, e, onde há exemplos suficientes, a atualização local soma-se ao que veio de fora.

O projeto entrega um método que separa o que se aprende do que se verifica e uma ferramenta que, por coordenada, devolve a ordem de suscetibilidade, a contribuição das variáveis, as fontes e o suporte. Para as comunidades que o motivaram, isso muda o ponto de partida: no domínio avaliado, um lugar que nunca entrou em um registro não precisa esperar pela próxima cheia para receber uma resposta fundamentada no terreno. Código e artefatos: https://github.com/gabriela-sofia/flood_Audit-Service.

Referências

[1] W. N. Adger, "Vulnerability," *Global Environ. Change*, vol. 16, pp. 268–281, 2006.

[2] IBGE, *Censo Demográfico 2022: Favelas e Comunidades Urbanas, resultados do universo*, 2a ed. Rio de Janeiro, 2025.

[3] T. Islam et al., "A systematic review of urban flood susceptibility mapping: remote sensing, machine learning, and other modeling approaches," *Remote Sens.*, vol. 17, art. 524, 2025.

[4] R. Bentivoglio et al., "Deep learning methods for flood mapping: a review of existing applications and future research directions," *Hydrol. Earth Syst. Sci.*, vol. 26, pp. 4345–4378, 2022.

[5] X. X. Zhu et al., "On the foundations of Earth foundation models," *Commun. Earth Environ.*, vol. 7, art. 103, 2026.

[6] F. Kratzert et al., "Toward improved predictions in ungauged basins: exploiting the power of machine learning," *Water Resour. Res.*, vol. 55, pp. 11344–11354, 2019.

[7] G. Nearing et al., "Global prediction of extreme floods in ungauged watersheds," *Nature*, vol. 627, pp. 559–563, 2024.

[8] G. Zhao et al., "Improving urban flood susceptibility mapping using transfer learning," *J. Hydrol.*, vol. 602, art. 126777, 2021.

[9] C. Ratté-Fortin et al., "A transferable deep learning framework for flood mapping: spatial generalization across hydro-climatic regimes using satellite imagery," *Int. J. Appl. Earth Obs. Geoinf.*, vol. 149, art. 105321, 2026.

[10] Copernicus Emergency Management Service, *Rapid Mapping: activations*, Comissão Europeia. https://mapping.emergency.copernicus.eu/

[11] R. Mukherjee et al., "Urban Flood Observations: a hand-labeled training and validation dataset of post-flood inundation," arXiv:2604.23066, 2026.

[12] D. Bonafilia et al., "Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1," in *Proc. CVPR Workshops*, 2020, pp. 835–845.

[13] B. Tellman et al., "Satellite imaging reveals increased proportion of population exposed to floods," *Nature*, vol. 596, pp. 80–86, 2021.

[14] H. Xu, "Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery," *Int. J. Remote Sens.*, vol. 27, pp. 3025–3033, 2006.

[15] J.-F. Pekel et al., "High-resolution mapping of global surface water and its long-term changes," *Nature*, vol. 540, pp. 418–422, 2016.

[16] I. Possantti et al., "Banco de dados das cheias na Região Hidrográfica do Lago Guaíba em maio de 2024," Zenodo, 2025, doi:10.5281/zenodo.14617475.

[17] SEDEC Recife, *Registro de atendimentos da Defesa Civil*, dados abertos. https://dados.recife.pe.gov.br

[18] S. J. Phillips et al., "Sample selection bias and presence-only distribution models: implications for background and pseudo-absence data," *Ecol. Appl.*, vol. 19, pp. 181–197, 2009.

[19] INPE e International Charter Space and Major Disasters, *Call 0864, Brazil RJ: componentes vetoriais de Petrópolis*, 2022. https://data.inpe.br/charter

[20] UFRJ/GEOCART, *Inventário histórico de deslizamentos*, camada do SIG municipal de Petrópolis. https://sig.petropolis.rj.gov.br

[21] L. Hawker et al., "A 30 m global map of elevation with forests and buildings removed," *Environ. Res. Lett.*, vol. 17, art. 024016, 2022.

[22] C. D. Rennó et al., "HAND, a new terrain descriptor using SRTM-DEM," *Remote Sens. Environ.*, vol. 112, pp. 3469–3481, 2008.

[23] K. J. Beven e M. J. Kirkby, "A physically based, variable contributing area model of basin hydrology," *Hydrol. Sci. Bull.*, vol. 24, pp. 43–69, 1979.

[24] M. Pesaresi, "GHS-BUILT-S R2023A: GHS built-up surface grid," Comissão Europeia, JRC, 2023.

[25] L. Poggio et al., "SoilGrids 2.0: producing soil information for the globe with quantified spatial uncertainty," *SOIL*, vol. 7, pp. 217–240, 2021.

[26] R. L. Prentice e R. Pyke, "Logistic disease incidence models and case-control studies," *Biometrika*, vol. 66, pp. 403–411, 1979.

[27] R. Merz e G. Blöschl, "A process typology of regional floods," *Water Resour. Res.*, vol. 39, no. 12, 2003.

[28] A. Dille et al., "Capturing the complete landslide–debris-rich flood continuum for accurate inventory, susceptibility and exposure mapping – lessons from Cyclone Idai," *Nat. Hazards Earth Syst. Sci.*, vol. 26, pp. 2561–2577, 2026.

[29] O. Ronneberger et al., "U-Net: convolutional networks for biomedical image segmentation," in *Proc. MICCAI*, 2015, pp. 234–241.

[30] K. He et al., "Masked autoencoders are scalable vision learners," in *Proc. CVPR*, 2022, pp. 16000–16009.

[31] Z. Li e D. Hoiem, "Learning without forgetting," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 40, pp. 2935–2947, 2018.

[32] A. M. J.-C. Wadoux et al., "Spatial cross-validation is not the right way to evaluate map accuracy," *Ecol. Model.*, vol. 457, art. 109692, 2021.

[33] J. Peters et al., "Causal inference by using invariant prediction: identification and confidence intervals," *J. R. Stat. Soc. B*, vol. 78, pp. 947–1012, 2016.

[34] D. Lopez-Paz e M. Ranzato, "Gradient episodic memory for continual learning," in *Proc. NeurIPS*, 2017.

[35] D. Li et al., "Disproportionate flood exposure for slum populations of the Global South," *Nat. Cities*, vol. 2, pp. 626–638, 2025.